

选题：从大语言模型中抽取长文本表示

一、研究目标

本项目主要研究以下内容：

- 复现并比较 PromptEOL 与 mean-pooling 两种长文本表示方法；
- 探索不同隐藏层对句子嵌入质量的影响；
- 分析 RoPE 位置编码频率对长文本表示效果的影响；
- 提出并验证多种长文本表示优化方案；
- 在 QMSum、2WikiMultihop、ArguAna 数据集上完成实验评估。

二、研究内容与计划

(1) 基础实验阶段

研究内容

- 使用 Mistral-Instruct-7B-0.3 模型；
- 实现：
 - PromptEOL 方法；
 - mean-pooling 方法；
- 比较不同 Transformer layer 的表示效果。

实验数据集

- QMSum
- 2WikiMultihop
- ArguAna

评估指标

根据数据集任务采用相应检索或相似度评价指标，例如：

- Recall
- MAP
- nDCG
- MRR

(2) 分析实验阶段

研究内容

① PromptEOL 与 mean-pooling 对比分析

重点分析：

- 为什么 mean-pooling 在长文本下可能更稳定；
- PromptEOL 的语义压缩优势与信息损失问题；
- 长文本中 token 数量对表示质量的影响。

② RoPE 位置编码研究

探索：

- 不同频率成分对长文本建模的影响；
- 长距离 token 的位置衰减问题；
- 高频/低频信息对语义聚合效果的贡献。

(3) 进阶优化阶段

计划从以下方向中进行优化：

研究点1：关键词增强加权池化

核心思想：

- 对重要 token 提高权重；
- 减少无关 token 对平均池化的干扰。

可能方法：

- attention score 加权；
- TF-IDF 权重；
- token saliency。

研究点2：长文本分块聚合（Chunk-based Aggregation）

核心思想：

- 将长文本切分为多个语义块；
- 分别编码后进行二次聚合。

目的：

- 缓解长距离语义衰减；
- 保留局部语义信息。

研究点3：语义压缩后再编码

核心思想：

- 先对长文本进行摘要压缩；
- 再提取文本表示。

可能方法：

- Prompt-based summarization；
- sliding summarization；
- hierarchical compression。

三、技术路线

整体流程如下：

1. 数据集预处理；
2. 长文本输入模型；
3. 提取 hidden states；
4. 不同 pooling 方法生成 embedding；
5. 相似度计算与检索评估；
6. 分析 layer 与 RoPE 影响；
7. 引入改进策略并进行实验对比。

四、分组情况

组长：王涵

组员：任奕弛